

Evaluación comparativa de detectores de eventos sismo-volcánicos para el Complejo Volcánico Nevados de Chillán

Informe de avance

Patricio Valdés Troncoso

Ingeniería Civil en Informática — Universidad Católica de Temuco

Profesor guía: Ricardo Soto

21 de agosto de 2026

Resumen

Se evalúan comparativamente tres detectores de eventos sismo-volcánicos —STA/LTA, PhaseNet y EQTransformer— sobre 10,18 horas de traza continua del Complejo Volcánico Nevados de Chillán, con 205 eventos anotados por especialistas de OVDAS. La evaluación se organiza en dos niveles, detección del instante y calidad del recorte, porque los tres detectores no producen la misma clase de salida. Los puntos de operación se obtienen por barrido de parámetros con un criterio común y se reporta la frontera de Pareto completa. En detección del instante los tres detectores resultan estadísticamente indistinguibles al medirlos globalmente; sin embargo, el desglose por clase revela diferencias significativas de signo opuesto que se cancelan al promediar. En calidad del recorte STA/LTA supera a EQTransformer de forma significativa y robusta frente al umbral de emparejamiento. Ningún detector domina en todas las clases: EQTransformer aventaja en eventos impulsivos (VT, AV, IC) y PhaseNet en eventos emergentes y sostenidos (LP, TR), con diferencias significativas en las cinco clases. Se identifica además que la duración mediana de los tremores excede la ventana fija de 8.192 muestras empleada por el clasificador, lo que constituye un argumento técnico para revisar su arquitectura.

1. Conjunto de datos

Se emplea el conjunto publicado en Zenodo (DOI 10.5281/zenodo.17163020, versión 4), asociado a Espinosa-Curilem *et al.* (2026). La traza continua se caracterizó empíricamente:

- Muestreo de 100 Hz; 3.664.193 muestras; 10,18 horas.
- Fila 0: tiempo Unix. Filas 1–8: ocho estaciones de **una sola componente**. Filas 9–14: máscaras one-hot (BG, VT, LP, TR, AV, IC).
- La traza **concatena tres segmentos de fechas distintas**, con cortes exactos en las horas 6 y 9 y saltos temporales de +1,9 y −3,0 años. Se excluyen guardas de 30 s en torno a cada unión, lo que reduce el catálogo evaluable de 205 a **203 eventos**; esta es la cifra empleada en todos los resultados que siguen.
- Canales utilizables: 1, 2, 3, 5 y 6. El canal 8 es idénticamente cero, el 7 carece de dato en el 70,8 % de la traza y el 4 presenta una desviación estándar dos órdenes de magnitud menor que sus vecinos.
- Los segmentos son heterogéneos por clase: el tercero, de 1,18 horas, concentra 29 de los 51 eventos IC. Esto confunde parcialmente las tasas por clase y se declara como limitación.

1.1. Duración de los eventos

Clase	n	Mínima	Mediana	Máxima
IC	51	3,4 s	8,8 s	18,7 s
AV	23	11,0 s	16,9 s	34,0 s
VT	38	7,5 s	15,6 s	27,7 s
LP	55	14,3 s	32,6 s	47,1 s
TR	38	30,4 s	87,8 s	240,8 s

Cuadro 1: Duración de los eventos catalogados por clase, sobre el catálogo completo de 205 eventos. Los resultados de evaluación emplean los 203 eventos que quedan tras excluir las guardas de unión.

Las ventanas del conjunto de entrenamiento del clasificador son de 8.192 muestras, equivalentes a **81,92 s**. La duración mediana de los tremores (87,8 s) la excede, de modo que más de la mitad de los eventos TR no caben en la ventana fija, y el más largo la triplica. En el extremo opuesto, un evento IC de 3,4 s ocupa apenas el 4 % de la ventana. Las figuras 1 y 2 ilustran el contraste.




Figura 1: Representación de entrada del clasificador para un evento IC de 8,8 s: espectrograma y forma de onda.




Figura 2: Misma representación para un tremor de 91,6 s. Ambos deben ingresar a una red de entrada de tamaño fijo, lo que obliga a estirar, rellenar o truncar la señal.

2. Detectores evaluados

STA/LTA. Algoritmo clásico, sin entrenamiento. Calcula la razón entre la energía de una ventana corta (*short-term average*) y una larga (*long-term average*) que la precede, y declara un disparo cuando esa razón supera un umbral de encendido, manteniéndolo hasta que cae bajo un umbral de apagado. Sus parámetros son las dos longitudes de ventana y los dos umbrales. Produce **intervalos** de forma natural, con inicio y fin. Su debilidad conocida frente a señales sostenidas es estructural: si la ventana larga es más corta que el evento, se llena con la propia señal, el contraste desaparece y el disparo se apaga prematuramente. Por eso la configuración óptima que arrojó el barrido usa una ventana larga de 60 s.

PhaseNet. Red convolucional con arquitectura tipo U-Net (Zhu y Beroza, 2019), entrenada sobre catálogos de sismicidad tectónica. Para cada muestra entrega la probabilidad de que corresponda a un arribo P, a un arribo S o a ruido. Su salida son **instantes**, no intervalos: el canal de ruido no significa “no ocurre nada”, sino “esta muestra no es un arribo”, de modo que durante la coda de un evento el modelo declara ruido con alta confianza. Por construcción no puede indicar dónde termina un evento.

EQTransformer. Red con mecanismos de atención (Mousavi *et al.*, 2020), entrenada sobre el conjunto STEAD. Dispone de tres salidas: detección de evento, arribo P y arribo S. La primera sí entrega **intervalos**, lo que lo convierte en el único de los dos modelos profundos comparable con STA/LTA en delimitación. Al haber sido calibrado sobre sismos tectónicos, cuyo intervalo de detección es corto, tiende a subestimar la extensión de los eventos volcánicos sostenidos.

Ambos modelos profundos se ejecutan mediante SeisBench con sus pesos preentrenados, sin reentrenamiento, en CPU.

3. Diseño de la evaluación

El catálogo no contiene arribos P/S, sino intervalos (`idx_start`, `idx_end`) en índices de muestra. La evaluación es, por tanto, de calidad del recorte y no de *picking*.

Los tres detectores no producen la misma clase de salida, de modo que compararlos mediante una única métrica sería injusto:

Detector	Salida nativa
STA/LTA	Intervalos (inicio y fin)
EQTransformer	Intervalos (canal <i>Detection</i>) y arribos P/S
PhaseNet	Solo arribos P/S: no delimita eventos

Cuadro 2: Naturaleza de la salida de cada detector.

De ahí que la evaluación se organice en dos niveles:

Nivel 1. Detección del momento. Se verifica si el detector marcó un inicio dentro de $\pm T$ segundos del inicio catalogado. Los tres compiten en igualdad de condiciones.

Nivel 2. Calidad del recorte. IoU, error de *offset* y sesgo de duración. PhaseNet queda excluido por construcción, y esa exclusión constituye en sí misma un resultado.

El emparejamiento entre detecciones y catálogo es una asignación uno a uno por IoU máximo. El punto de operación de cada detector se obtiene por barrido de parámetros bajo un criterio común: 324 combinaciones para STA/LTA y barrido del umbral de confianza para los modelos profundos. El marco fue verificado mediante casos sintéticos con solución conocida.

Conviene señalar que esta división en dos niveles no es una convención introducida para esta evaluación, sino que **reproduce la arquitectura del sistema en operación**: `ovdas-core` separa la delimitación del evento, a cargo de `cesvec.detection()`, de la identificación del arribo P, a cargo de `workerpick.py`. Los dos niveles evaluados se corresponden con esos dos módulos.

4. Resultados

4.1. Nivel 1: detección del momento

Detector	Recall	Precisión	F1	Falsos/h	Error <i>onset</i>
EQTransformer	0,581	0,615	0,597	7,29	1,74 s
STA/LTA	0,542	0,598	0,568	7,29	2,36 s
PhaseNet	0,527	0,598	0,560	7,10	1,99 s

Cuadro 3: Nivel 1, punto de mejor F1 con tolerancia de ± 5 s.

Los tres detectores quedan dentro de 0,04 de F1, y un análisis de significancia (sección 6) muestra que esa separación **no es estadísticamente distinguible del ruido de muestreo**. Conviene adelantar, sin embargo, que esa equivalencia global no implica comportamiento similar: el desglose por clase revela diferencias significativas de signo opuesto que se cancelan al promediar.

En precisión del instante los modelos profundos aciertan el inicio con 1,7–2,0 s de error medio absoluto frente a 2,4 s de STA/LTA, y esa ventaja se mantiene en toda la frontera.

El techo de recall alcanzable difiere de manera marcada: PhaseNet llega a 0,946 y STA/LTA a 0,921, ambos a costa de precisión muy baja, mientras que EQTransformer no supera 0,773 en ninguna configuración. La figura 3 muestra el espacio de operación completo.




Figura 3: Frontera precisión-recall de los tres detectores en el Nivel 1. Los puntos tenues corresponden a todas las configuraciones evaluadas; las líneas unen los puntos no dominados.

La frontera revela un matiz que el punto único de la tabla 3 no captura. PhaseNet domina a EQTransformer en prácticamente todo el rango de recall inferior a 0,55, y con márgenes considerables: a recall 0,20 alcanza precisión 0,95 frente a 0,82, y a recall 0,35 alcanza 0,90 frente a 0,70. Ambas fronteras se cruzan alrededor de recall 0,58, de modo que la ventaja de EQTransformer en F1 corresponde a una franja estrecha del espacio de operación. Por encima de recall 0,78 EQTransformer no alcanza ninguna configuración, mientras que PhaseNet y STA/LTA llegan a 0,95 y 0,92 respectivamente, a costa de precisión muy baja. Esta es precisamente la razón por la que conviene reportar la frontera completa y no un punto aislado: la elección del mejor detector depende del régimen de operación.

4.2. Nivel 2: calidad del recorte

Métrica	STA/LTA	EQTransformer
Recall	0,626	0,330
Precisión	0,545	0,465
F1	0,583	0,386
IoU medio	0,563	0,479
Error de <i>onset</i> (MAE)	3,07 s	13,22 s
Sesgo de duración	-7,59 s	-1,37 s

Cuadro 4: Nivel 2, cada detector en su punto de mejor F1 tras barrido equivalente.

STA/LTA gana con claridad, y mantiene la ventaja después de que EQTransformer fue barrido con la misma profundidad. Corresponde señalar, sin embargo, que EQTransformer estima mejor la duración de los pocos eventos que logra delimitar.

Ambos detectores presentan sesgo de duración negativo: recortan los eventos antes de tiempo.

El comportamiento tiene explicación física, ya que el inicio de un evento es un cambio brusco de energía, fácil de detectar, mientras que el final es una decaída gradual que se confunde con el ruido de fondo.

Corresponde advertir que el IoU medio y el sesgo de duración se calculan únicamente sobre los eventos emparejados, es decir, aquellos cuyo IoU superó el umbral de 0,30. Los eventos peor delimitados quedan excluidos del promedio por construcción, de modo que ambas cifras subestiman la severidad del problema. El efecto es más acusado en la clase TR, donde algo más de la mitad de los eventos no alcanzó a emparejarse.

4.3. Complementariedad por clase

Clase	STA/LTA	PhaseNet	EQTransformer
VT	0,763	0,553	0,842
LP	0,873	0,945	0,745
TR	0,432	0,649	0,270
AV	0,478	0,304	0,739
IC	0,120	0,060	0,360

Cuadro 5: Recall por clase en el Nivel 1, mismo punto de operación.

Ningún detector domina en todas las clases. EQTransformer aventaja en eventos impulsivos y de corta duración (VT, AV, IC), semejantes a los sismos tectónicos con los que fue entrenado, mientras que PhaseNet aventaja en eventos emergentes y sostenidos (LP, TR). El patrón admite explicación física y sugiere que una estrategia combinada superaría a cualquier detector individual.

A diferencia de las métricas globales, estas diferencias **sí resultan estadísticamente significativas**: la comparación entre PhaseNet y EQTransformer lo es en las cinco clases (sección 6). Este resultado explica además por qué ambos detectores parecen equivalentes al medirlos globalmente: sus ventajas van en direcciones opuestas según la clase y se cancelan al promediar.

5. Hallazgos metodológicos

5.1. El relleno de componentes altera el rango alcanzable

Los datos disponen de una sola componente por estación, mientras que ambos modelos esperan tripletas Z–N–E. Al rellenar con ceros, PhaseNet genera 1.588 arribos y su recall **no supera 0,527** por más que se reduzca el umbral; al duplicar la componente vertical genera 9.559 arribos y alcanza 0,946. No se trata de que una estrategia sea mejor, sino de que cada una define un techo distinto. En EQTransformer el efecto es inverso. La estrategia óptima depende del modelo y debe declararse como decisión metodológica.

5.2. Los falsos positivos no constituyen una categoría única

Origen	n	%	Clase asociada
Fragmento de evento catalogado	22	20,8	TR: 19 de 22
Adyacente (< 60 s de un evento)	38	35,8	LP 13, IC 12, VT 7
Aislado	46	43,4	IC 15, VT 13, AV 10

Cuadro 6: Origen de los 106 falsos positivos de STA/LTA.

Los 22 fragmentos **no son alarmas espurias**: corresponden a eventos reales recortados con tal brevedad que su IoU cayó bajo el umbral de 0,30, por lo que se contabilizaron simultáneamente como perdidos y como falsos positivos. Diecinueve de veintidós son tremores, lo que identifica la fragmentación de tremores como el modo de fallo principal de STA/LTA y muestra que recall y precisión están deprimidos por una misma causa.

La figura 4 muestra el mecanismo directamente sobre la señal, y la figura 5 su consecuencia en el conteo de métricas.




Figura 4: Tremor de 91,6 s. El disparo de STA/LTA (panel inferior, en gris) cubre alrededor de 13 s del evento, apenas un 13 % de su extensión, lo que sitúa el IoU muy por debajo del umbral de emparejamiento. Los intervalos rayados corresponden a otros eventos del catálogo presentes en la ventana.




Figura 5: Consecuencia del recorte incompleto: el detector captura 22,9 s a partir del inicio de un tremor catalogado, con lo que el IoU queda bajo el umbral y la misma detección se contabiliza como evento perdido y como falso positivo.

5.3. La precisión reportada constituye una cota inferior

Un análisis de relación señal/ruido muestra que el 58 % de los falsos positivos alcanza niveles comparables a los de eventos catalogados (mediana 17,8 dB), frente al 6 % de tramos de fondo tomados al azar (mediana 9,9 dB). Parte de esa señal proviene de eventos catalogados mal emparejados, pero el 43 % corresponde a detecciones aisladas, a más de 60 s de cualquier evento del catálogo.

La figura 6 muestra una omisión del catálogo observable directamente sobre la señal, y la figura 7 una detección aislada representativa.




Figura 6: Ventana en torno a un evento VT catalogado. El encabezado indica que no hay otros eventos del catálogo en la ventana; sin embargo, alrededor del segundo 16 se aprecia una señal sísmica clara, de amplitud comparable a la del evento anotado, que tanto PhaseNet como EQTransformer marcan. Casos como este explican parte de las detecciones contabilizadas como falsos positivos.




Figura 7: Detección aislada, a 192 s del evento catalogado más próximo, con señal sostenida de baja frecuencia y arranque emergente.

Queda como pregunta abierta si el catálogo de referencia anota todos los eventos presentes en la traza o únicamente aquellos clasificados como de interés para el reporte del observatorio.

5.4. La tolerancia de ± 1 s está bajo la resolución del catálogo

Los tres detectores caen a recall entre 0,08 y 0,20 con tolerancia de ± 1 s. El inicio catalogado fue marcado por un analista humano y, en eventos emergentes como LP y TR, presenta incertidumbre propia del orden del segundo, por lo que esa tolerancia mide en parte la variabilidad del catálogo y no solo el desempeño del detector.

6. Significancia estadística y robustez

Con 203 eventos, el intervalo de confianza del 95 % de cualquier recall ronda $\pm 0,07$. Diferencias del orden de 0,04 entre detectores caen por tanto dentro del ruido de muestreo. Para verificarlo se calcularon intervalos por *bootstrap* con 2.000 remuestreos, apareados sobre los mismos índices de evento, ya que los tres detectores se evaluaron sobre el mismo catálogo.

6.1. Nivel 1: las diferencias no son distinguibles

Comparación	Diferencia	IC 95 %
STA/LTA – PhaseNet	+0,015	[−0,044 , +0,069]
STA/LTA – EQTransformer	−0,041	[−0,113 , +0,039]
PhaseNet – EQTransformer	−0,056	[−0,138 , +0,025]

Cuadro 7: Diferencias de recall de *onset* entre detectores, con intervalo de confianza del 95 % por *bootstrap* pareado. Las tres incluyen el cero.

Las tres comparaciones incluyen el cero, de modo que ninguna permite afirmar superioridad de un detector sobre otro en recall de detección del instante. Los intervalos individuales son [0,473 , 0,611] para STA/LTA, [0,458 , 0,596] para PhaseNet y [0,512 , 0,650] para EQTransformer, y se solapan ampliamente entre sí.

6.2. Por clase: las diferencias sí son significativas y se cancelan

El análisis se repitió dentro de cada clase, remuestreando únicamente los eventos de esa clase, de modo que el intervalo refleja su tamaño real (entre 23 eventos para AV y 55 para LP) y no el del catálogo completo.

Clase	n	STA/LTA – PN	STA/LTA – EQT	PN – EQT
VT	38	+0,212*	−0,078	−0,290*
LP	55	−0,074	+0,129	+0,199*
TR	37	−0,216*	+0,161	+0,374*
AV	23	+0,175	−0,263	−0,432*
IC	50	+0,059	−0,240*	−0,301*

Cuadro 8: Diferencias de recall dentro de cada clase. PN = PhaseNet, EQT = EQTransformer. El asterisco indica que el intervalo de confianza del 95 % excluye el cero. Ocho de quince comparaciones resultan significativas.

La comparación entre PhaseNet y EQTransformer resulta significativa en **las cinco clases**, con signos alternados: PhaseNet supera a EQTransformer en LP y TR, y EQTransformer supera a PhaseNet en VT, AV e IC. Sin embargo, la diferencia global entre ambos es de apenas $-0,056$ con un intervalo que incluye el cero.

Esta aparente contradicción tiene una explicación directa: **las ventajas se cancelan al promediar sobre el catálogo completo**. La equivalencia global no indica que los detectores se comporten de forma similar, sino que sus diferencias apuntan en direcciones opuestas según el tipo de evento. De ello se sigue una consecuencia metodológica: reportar un único valor de recall global para un detector sismo-volcánico oculta información esencial sobre su comportamiento, y el desglose por clase debería considerarse parte obligatoria de la evaluación.

STA/LTA ocupa una posición intermedia: supera significativamente a PhaseNet en VT, es superado significativamente por PhaseNet en TR, y es superado por EQTransformer en IC. En las restantes comparaciones no se distingue de ninguno de los dos.

6.3. Nivel 2: el resultado no depende del umbral elegido

El umbral de $\text{IoU} \geq 0,30$ empleado para el emparejamiento es una decisión metodológica, de modo que corresponde verificar que las conclusiones no dependan de ella.

IoU mín.	STA/LTA	EQTransf.	Diferencia (IC 95 %)
0,10	0,700	0,532	+0,168 [+0,099 , +0,241]
0,20	0,665	0,458	+0,207 [+0,128 , +0,281]
0,30	0,626	0,330	+0,296 [+0,217 , +0,379]
0,40	0,527	0,227	+0,299 [+0,217 , +0,384]
0,50	0,374	0,108	+0,266 [+0,187 , +0,345]

Cuadro 9: Recall del Nivel 2 en función del umbral de IoU. Todas las diferencias son estadísticamente significativas.

STA/LTA supera a EQTransformer en los cinco umbrales evaluados, y en todos los casos el intervalo de confianza de la diferencia excluye el cero. La ventaja además *crece* al exigir un recorte más ajustado, pasando de +0,17 con IoU 0,10 a +0,30 con IoU 0,40. La conclusión del Nivel 2 es por tanto robusta y no es un artefacto del umbral elegido.

Corresponde matizar un aspecto: con el criterio más permisivo ($\text{IoU} \geq 0,10$) EQTransformer alcanza mayor precisión que STA/LTA (0,750 frente a 0,609) y su F1 queda prácticamente empatado (0,622 frente a 0,651). Detecta menos eventos, pero se equivoca menos al hacerlo. La ventaja de STA/LTA se manifiesta al exigir delimitación precisa, no al exigir únicamente coincidencia temporal aproximada.

7. Decisiones pendientes

1. **Criterio del punto de operación.** ¿Pesa más no perder eventos o no generar falsas alarmas? La respuesta determina qué detector resulta preferible y debe aplicarse por igual a los tres.
2. **¿Un detector o una combinación?** Los resultados sugieren complementariedad por clase de evento.
3. **Definición del detector clásico de referencia.** El sistema *ovdas-core* emplea dos mecanismos distintos. Para *delimitar* eventos, `cesvec.detection()` aplica un umbral de amplitud absoluta (504 cuentas) sobre la señal filtrada y suaviza la serie binaria resultante con un filtro FIR de 501 coeficientes, pasabanda estrecho centrado en 1,34 Hz, que privilegia la actividad sostenida sobre los picos aislados. Para *identificar el arribo* *P*, `workerpick.py` calcula una razón de amplitudes entre ventanas de 4 s y 1 s, emparentada con STA/LTA aunque no idéntica, ya que emplea máximos en lugar de promedios.

El umbral de 504 cuentas es absoluto y depende de la ganancia del instrumento, por lo que el detector no se adapta al ruido de fondo ni a cambios de estación. Evaluar este detector junto a los tres ya medidos permitiría comparar contra el sistema efectivamente desplegado y no solo contra una referencia genérica de la literatura.

8. Estado y trabajo siguiente

La etapa de detección se considera cerrada: conjunto de datos caracterizado, marco de evaluación en dos niveles verificado, tres detectores medidos con barrido de parámetros, fronteras de Pareto, análisis del origen de los falsos positivos, intervalos de confianza por *bootstrap* y verificación de robustez frente al umbral de emparejamiento.

El trabajo siguiente, en orden, es: definir detector y punto de operación; recortar los eventos del catálogo con el detector elegido; replicar los parámetros de espectrograma del repositorio de referencia; adaptar el clasificador VGG16 de tres a cinco clases, incorporando AV e IC como clases etiquetadas en lugar de derivarlas al detector de fuera de distribución; y reentrenar en Google Colab, única etapa que requiere GPU.

Cabe señalar que la salida del detector tiene duración variable, entre 3,4 s y 240,8 s, mientras que la entrada del VGG16 es de tamaño fijo. Esa incompatibilidad obliga a estirar, rellenar o truncar cada recorte, y constituye el argumento técnico concreto para revisar la arquitectura del clasificador más allá de su antigüedad.